GEN AI 인텐시브 과정

강사 장철원

Section 0

코스소개

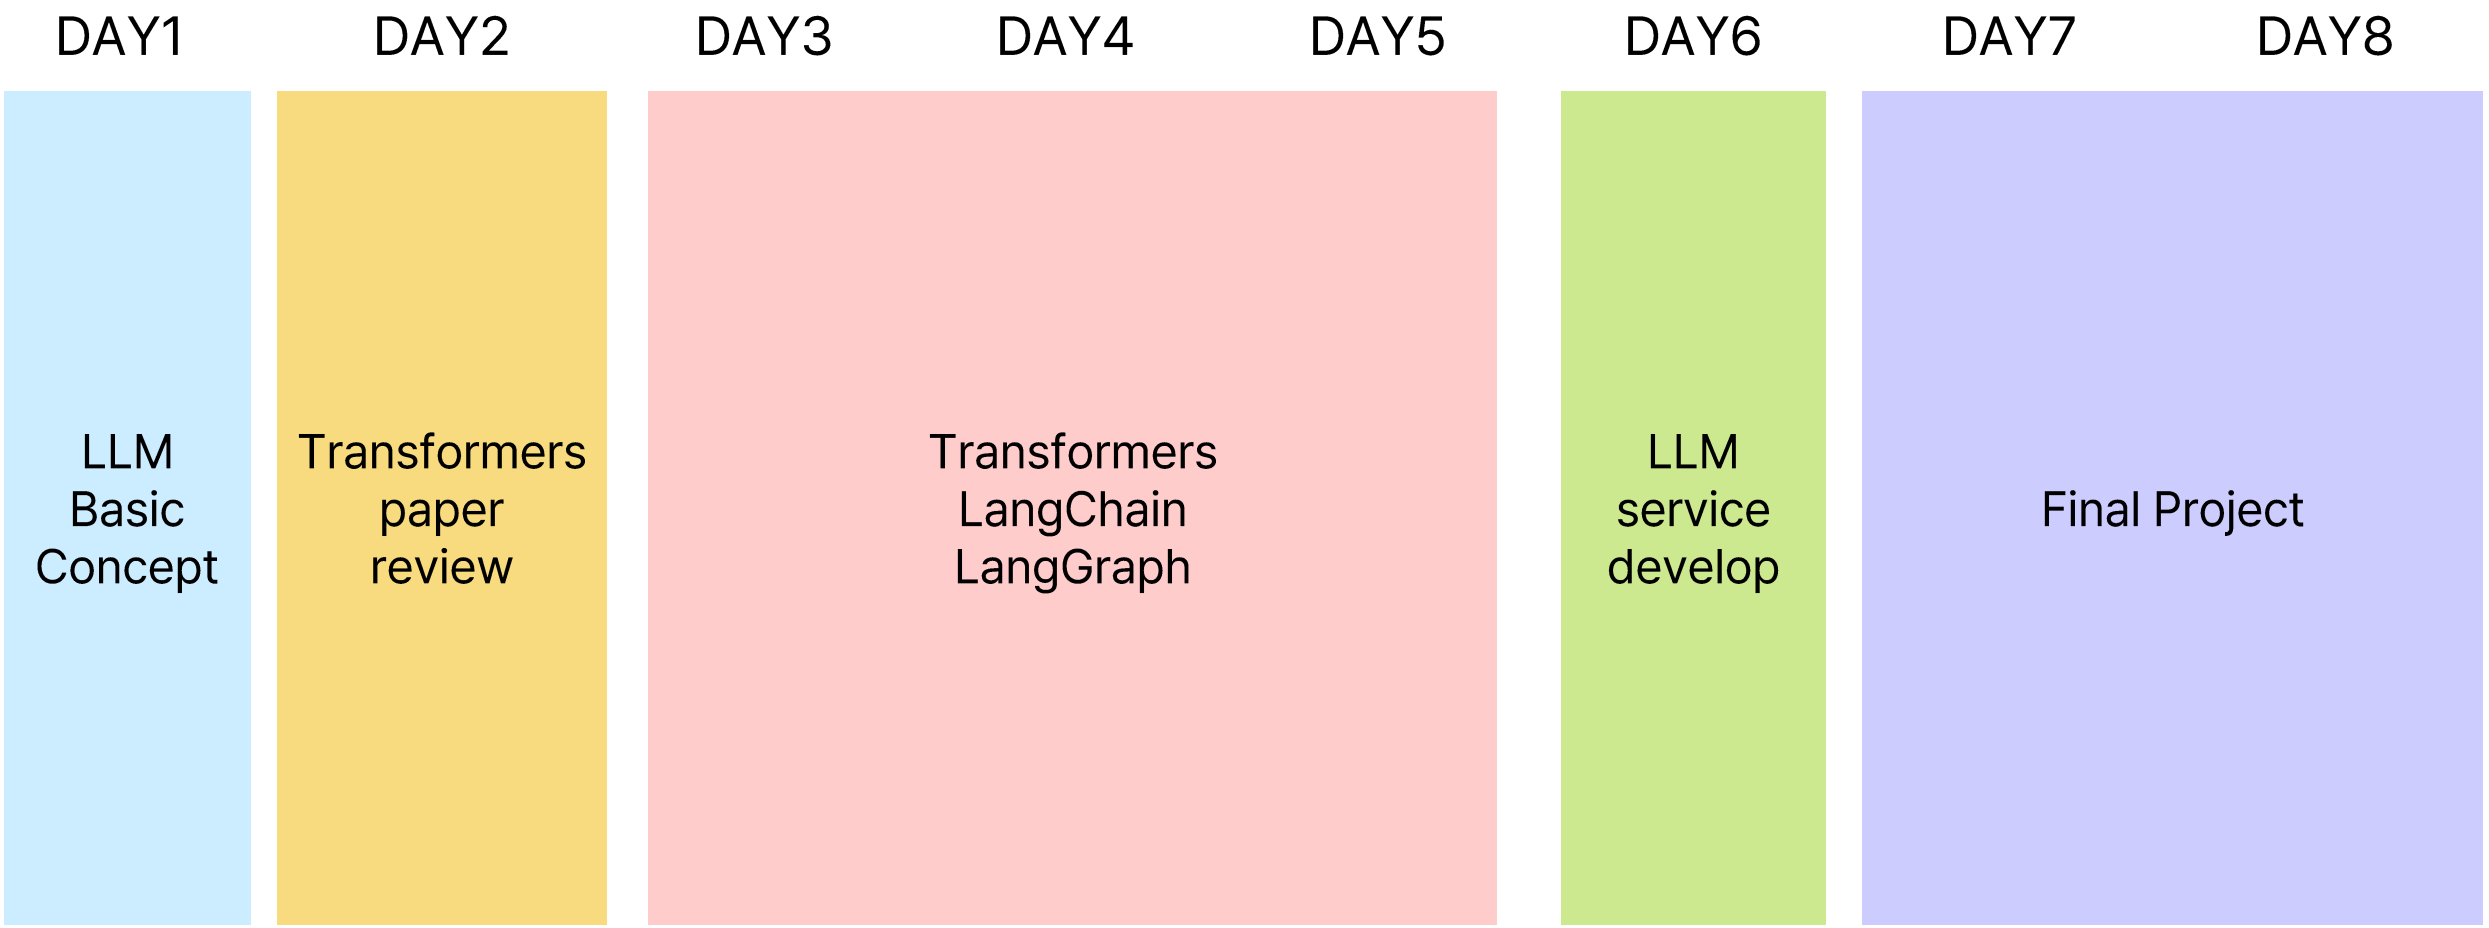

Section 0

목차

❑ LangGraph 기초

❑ LangGraph + LangChain

GEN AI 인텐시브 과정

Section 1. LangGraph

Section 1-1. LangGraph의 개념

LangGraph

- LangChian 팀이 만든 LLM 기반 에이전트 워크플로우 프레임워크

복잡한 LLM 시스템을 그래프 기반으로 정의할 수 있게 해주는 도구

LangGraph의 구성 요소

- 노드(Node) = 하나의 처리 단계(예, 질문 분석, 검색, 요약 등)
- 엣지(Edge) = 조건에 따라 다음 단계로 이동
- 상태(State) = LLM의 기억이나 진행 상황을 계속 유지

LangChain만으로 충분하지 않나요?

- LangChain은 대부분 단순 순차적 흐름 사용
  - 복잡한 조건 분기 / 반복 / 상태 추적 / 도구 선택 / 다단계 추론 구현이 어려움
  - Ex) “정보가 부족하니 검색 다시해봐 " 와 같은 반복 루프 처리 어려움
- 따라서 Graph 구조를 사용하는 LangGraph 필요

LangGraph의 특징

- stateful 에이전트 구성 가능(모든 노드 상태에 전달됨)
- 명시적 흐름 제어 가능(분기, 반복, 종료 조건 등 쉽게 구현 가능)
- LangChain과 호환 가능

LangChain vs LangGraph

LangChain

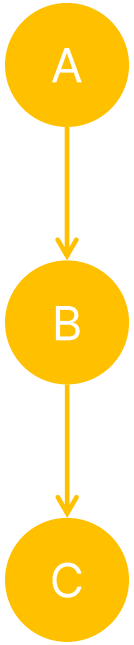

LangGraph

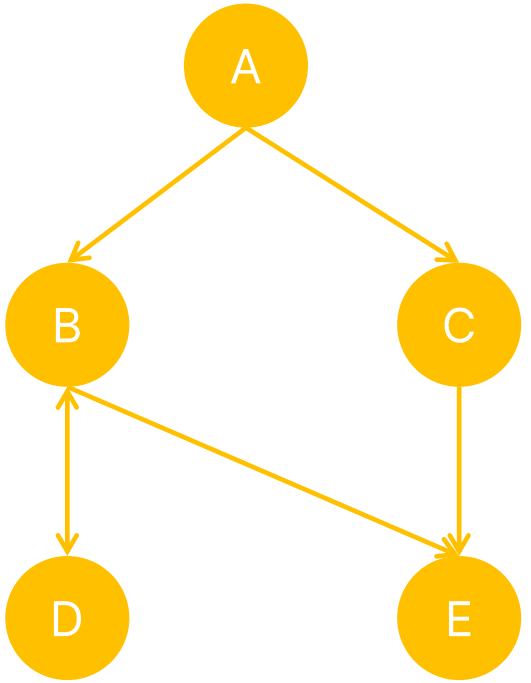

transformers vs langchain vs langgraph

항목	transformers	langchain	langgraph
역할	LLM 모델 활용	LLM을 활용한 앱, 시스템 구축	복잡한 상태 추론/흐름 관리
개발 수준	낮은 수준(Low level)	높은 수준(High level)	Workflow-level
기능	모델 불러오기, 토크나이징, 추론	프롬프트 설계, 문서 검색, 멀티 스텝 추론, 메모리 등	분기/루프 포함 복잡한 Agent 구조 설계
비유	자동차 엔진	자동차	자율주행 자동차

GEN AI 인텐시브 과정

Section 1. LangGraph

Section 1-2. LangGraph 헬로 월드

실습 내용

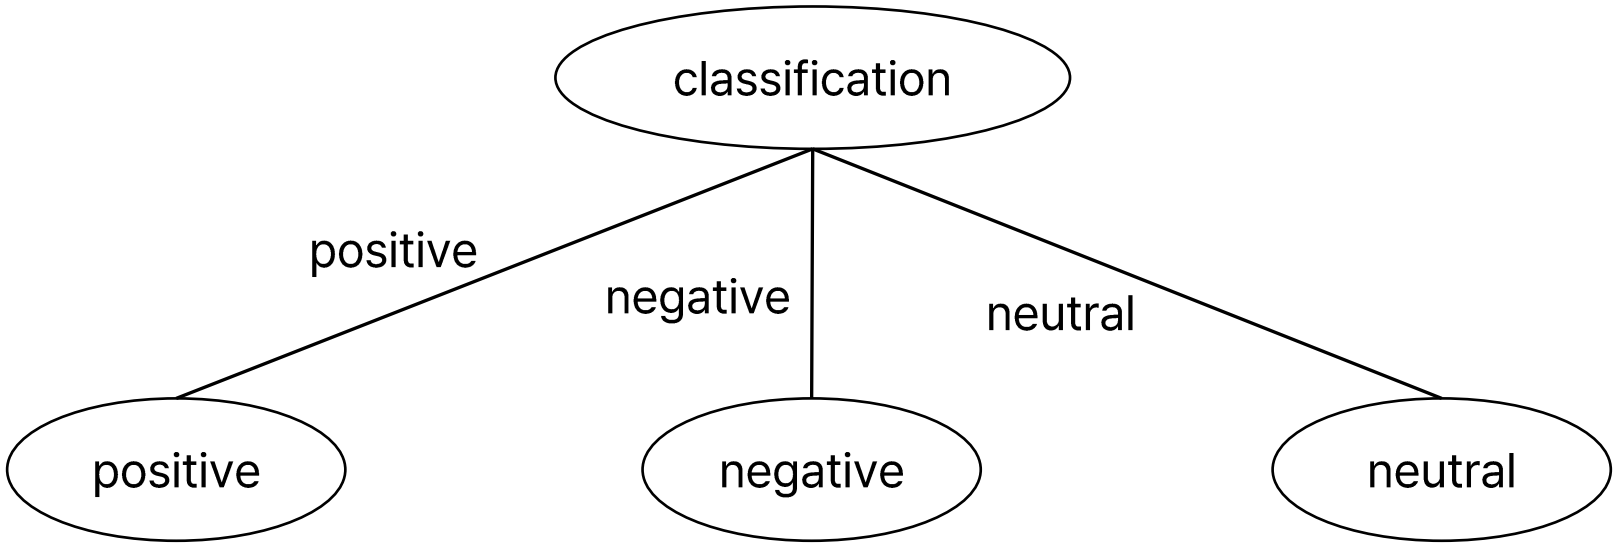
classification
positive
negative
neutral
positive
negative
neutral

라이브러리 불러오기

```python
from langgraph.graph import StateGraph, END
```

상태 기반의 대화 흐름 구성에 사용
(상태는 딕셔너리 기반으로 표현)

그래프 흐름의 종료 지점을 나타낼 때 사용

Section

LangGraph 헬로 월드

노드 설정

```python
# 1. 분류 노드
def classification(state):
    text = state.get("user_input", "")

    if any(word in text for word in ["좋아요", "네", "좋다", "응"]):
        label = "positive"
    elif any(word in text for word in ["싫어요", "아니요", "별로", "싫다"]):
        label = "negative"
    else:
        label = "neutral"
    return {**state, "label": label}

# 2. 응답 노드
def positive_answer(state):
    return {**state, "response": "좋게 생각해주셔서 감사합니다!"}

def negative_answer(state):
    return {**state, "response": "무엇이 불편하셨나요?"}

def neutral_answer(state):
    return {**state, "response": "조금 더 자세히 말씀해 주세요."}
```

해당 key가 없을 때 빈 문자열 반환

그래프 설계

```python
# 4. 그래프 설계
graph = StateGraph(dict)

graph.add_node("classification", classification)
graph.add_node("positive", positive_answer)
graph.add_node("negative", negative_answer)
graph.add_node("neutral", neutral_answer)

graph.set_entry_point("classification")
```

그래프에서 상태로 다룰 데이터 타입

노드 이름

이 노드에서 실행될 함수

그래프 흐름에서 시작 노드 지정

```
<langgraph.graph.state.StateGraph at 0x1bb884b4210>
```

엣지 추가

```python
def get_label(state):
    return state.get("label", "")
```

```python
# 분류 후 label에 따라 분기
graph.add_conditional_edges("classification", get_label, {
    "positive": "positive",
    "negative": "negative",
    "neutral": "neutral"
})
```

"classification" 노드의 실행 결과 label이
"positive"이면 "positive" 노드로 이동
"negative"이면 "negative" 노드로 이동
"neutral"이면 "neutral" 노드로 이동

```
<langgraph.graph.state.StateGraph at 0x1bb884b4210>
```

엣지 추가

```
# 각 노드 끝나면 종료
graph.add_edge("positive", END)
graph.add_edge("negative", END)
graph.add_edge("neutral", END)
```

"positive" 노드가 실행된 후에는 그래프 종료

"negative" 노드가 실행된 후에는 그래프 종료

"neutral" 노드가 실행된 후에는 그래프 종료

```
<langgraph.graph.state.StateGraph at 0x1bb884b4210>
```

add_edge vs add_conditional_edges

`add_edge("A", "B")` → 무조건 A에서 B로 이동

`add_conditional_edges("A", 조건함수, 분기맵)` → 조건에 따라 다른 노드로 이동

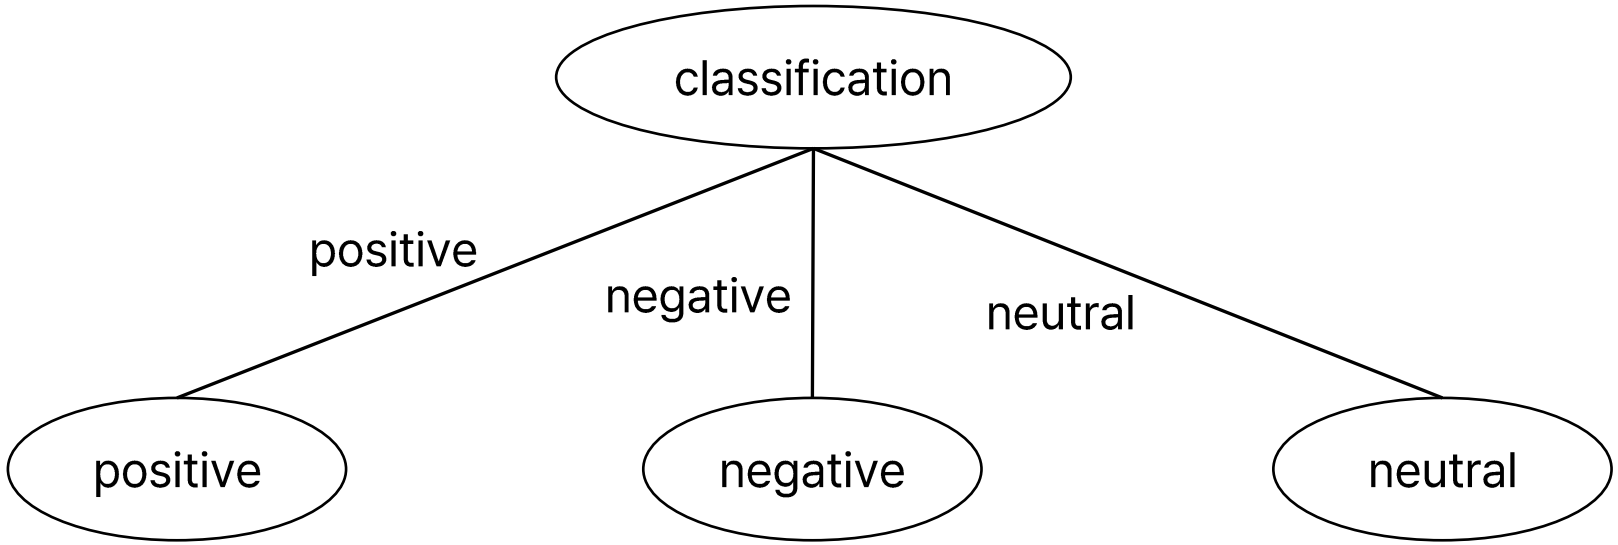

그래프 실행

```
# 5. 실행기 구성
app = graph.compile()
```

앞서 만든 그래프 설계도를 컴파일해서 앱으로 생성

```
# 6. 테스트 실행 (한글 입력)
user_input = input("한글 입력: ")
```

```
한글 입력:  이 서비스 너무 좋아요.
```

앞서 함수 생성할 때 “user_input”을 사용했으므로

```
final_state = app.invoke({"user_input": user_input})
print("응답:", final_state.get("response", ""))
```

```
응답: 좋게 생각해주셔서 감사합니다!
```

GEN AI 인텐시브 과정

Section 1. LangGraph

Section 1-3. LangGraph + LangChain

실습 내용

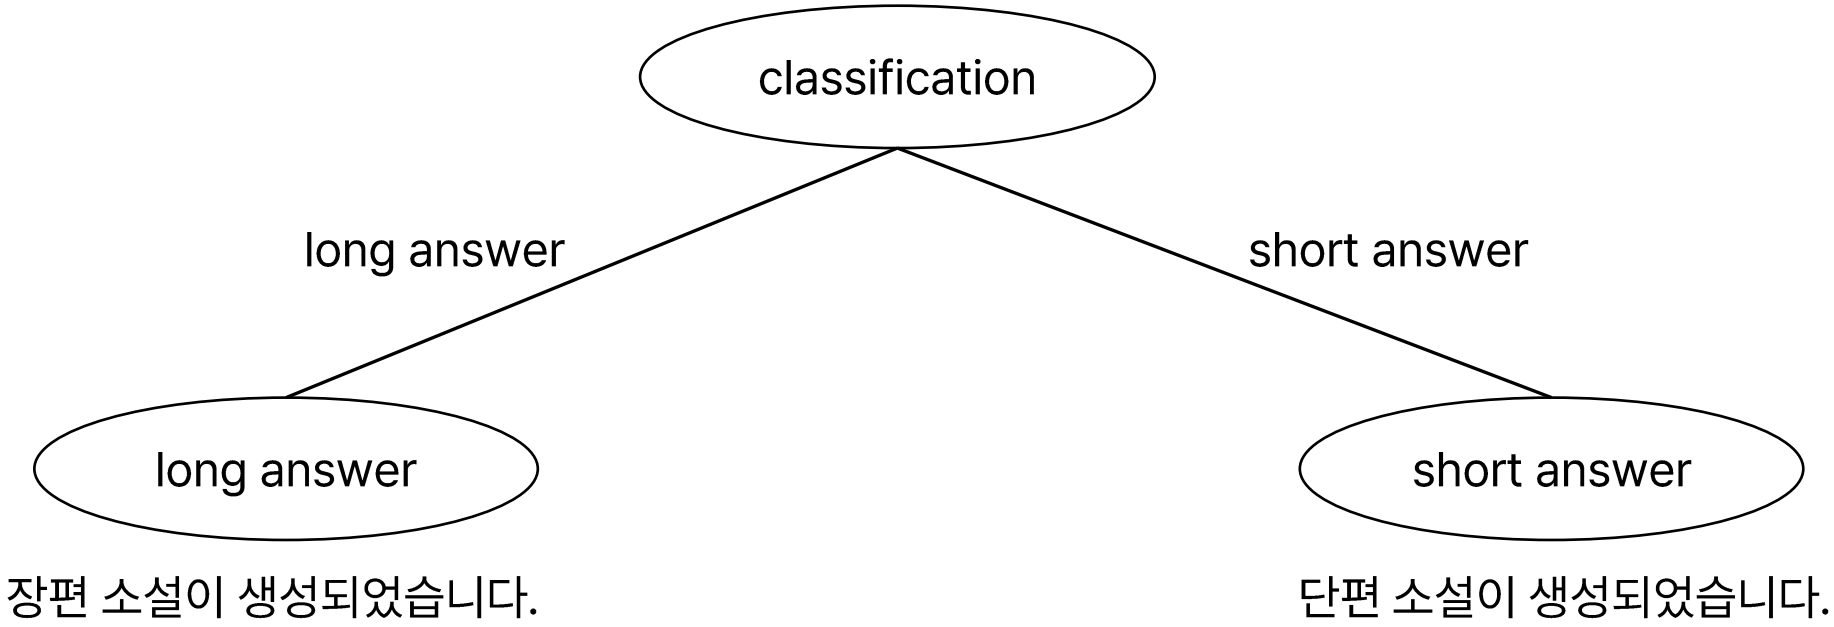
classification
long answer
short answer
long answer
short answer
장편 소설이 생성되었습니다.
단편 소설이 생성되었습니다.

LangGraph + LangChain

[1]:
```
from langgraph.graph import StateGraph, END
from langchain_huggingface import HuggingFacePipeline
from langchain_core.prompts import PromptTemplate
from transformers import AutoTokenizer, AutoModelForCausalLM, pipeline
```

[2]:
```
# 1. 한글 가능한 모델 설정
model_id = "skt/kogpt2-base-v2"
tokenizer = AutoTokenizer.from_pretrained(model_id)
model = AutoModelForCausalLM.from_pretrained(model_id)
```

[3]:
```
# 2. 파이프라인
text_gen = pipeline(
    "text-generation",
    model=model,
    tokenizer=tokenizer,
    truncation=False,
    max_new_tokens=100,
    do_sample=True,
    return_full_text=True,
    temperature=0.7)

llm = HuggingFacePipeline(pipeline=text_gen)
```

새로운 토큰 생성 갯수

템플릿까지 출력할 것인지?

[4]:
```
# 3. 프롬프트 및 체인 생성
prompt = PromptTemplate.from_template("아주 먼 옛날 {user_input}이 살고 있었습니다. 그러던 어느날 ")
chain = prompt | llm
```

LangGraph + LangChain

```
result1 = chain.invoke({"user_input": "토끼"})
print(result1)
```

```
아주 먼 옛날 토끼이 살고 있었습니다. 그러던 어느날 뚱뚱한 토끼가 와서 토끼에게 물었습니다." 토끼는 고개를 갸우뚱했습니다.
"그랬구나. 나는 토끼를 도울 수 있는 방법을 찾았습니다." 토끼는 이렇게 대답했습니다.
"이 방법은 아주 간단하고 좋습니다." 토끼는 정말 용감했습니다.
"나는 토끼에게 물었습니다." 토끼는 이렇게 말했습니다.
"물고기가 토끼에게 물었을 때, 나는, 토끼가 물었을 때 나는 놀라서 울었지. 그런데 그 물음에 나는
```

```
len(result1)
```

```
246
```

```
result2 = chain.invoke({"user_input": "고양이"})
print(result2)
```

```
아주 먼 옛날 고양이이 살고 있었습니다. 그러던 어느날 댁이 찾아왔습니다. 고양이의 주인이며 그 집 아주머니는 바로 댁의 부인이었습니다. 그런데 이 고양이는 아주머니의 집 근처에도 잘 보이지 않았습니다. 물론 이 고양이는 이 집에서 멀리 떨어진 한적한 시골마을에 살고 있는 것 같았습니다. 그런데 이 고양이가 이 작은 시골마을에 사는 것을 알게 된 순간, 댁은 아주머니에게 그 일을 맡기고 싶었습니다."
"그렇습니다. 그런데 그 고양이의 주인은 다름 아닌 아주머니였습니다. 그 고양이는
```

```
len(result2)
```

```
272
```

LangGraph + LangChain

```python
# 3. 판단 노드
def classification(state):
    user_input = state.get("user_input", "")
    result = chain.invoke({"user_input": user_input}).strip()

    if len(result) > 250:
        label = "long_answer"
    else:
        label = "short_answer"

    return {**state, "label": label}

# 4. 응답 노드
def long_answer(state):
    return {**state, "response": "장편 소설이 생성되었습니다."}

def short_answer(state):
    return {**state, "response": "단편 소설이 생성되었습니다."}
```

```python
def get_label(state):
    return state.get("label", "")
```

LangGraph + LangChain

```python
# 5. LangGraph 구성
graph = StateGraph(dict)

graph.add_node("classification", classification)
graph.add_node("long_answer", long_answer)
graph.add_node("short_answer", short_answer)

graph.set_entry_point("classification")

graph.add_conditional_edges("classification", get_label, {
    "long_answer": "long_answer",
    "short_answer": "short_answer"
})

graph.add_edge("long_answer", END)
graph.add_edge("short_answer", END)
```

```
<langgraph.graph.state.StateGraph at 0x226ff287350>
```

```python
# 6. 실행
app = graph.compile()

user_input = input("이야기를 만들고 싶은 동물 입력: ")
final_state = app.invoke({"user_input": user_input})
print("응답:", final_state.get("response",""))
```

```
이야기를 만들고 싶은 동물 입력:  거북이
응답: 장편 소설이 생성되었습니다.
```

GEN AI 인텐시브 과정

Section 1. LangGraph

Section 1-4. LangGraph + LangChain + multi-turn

실습 내용

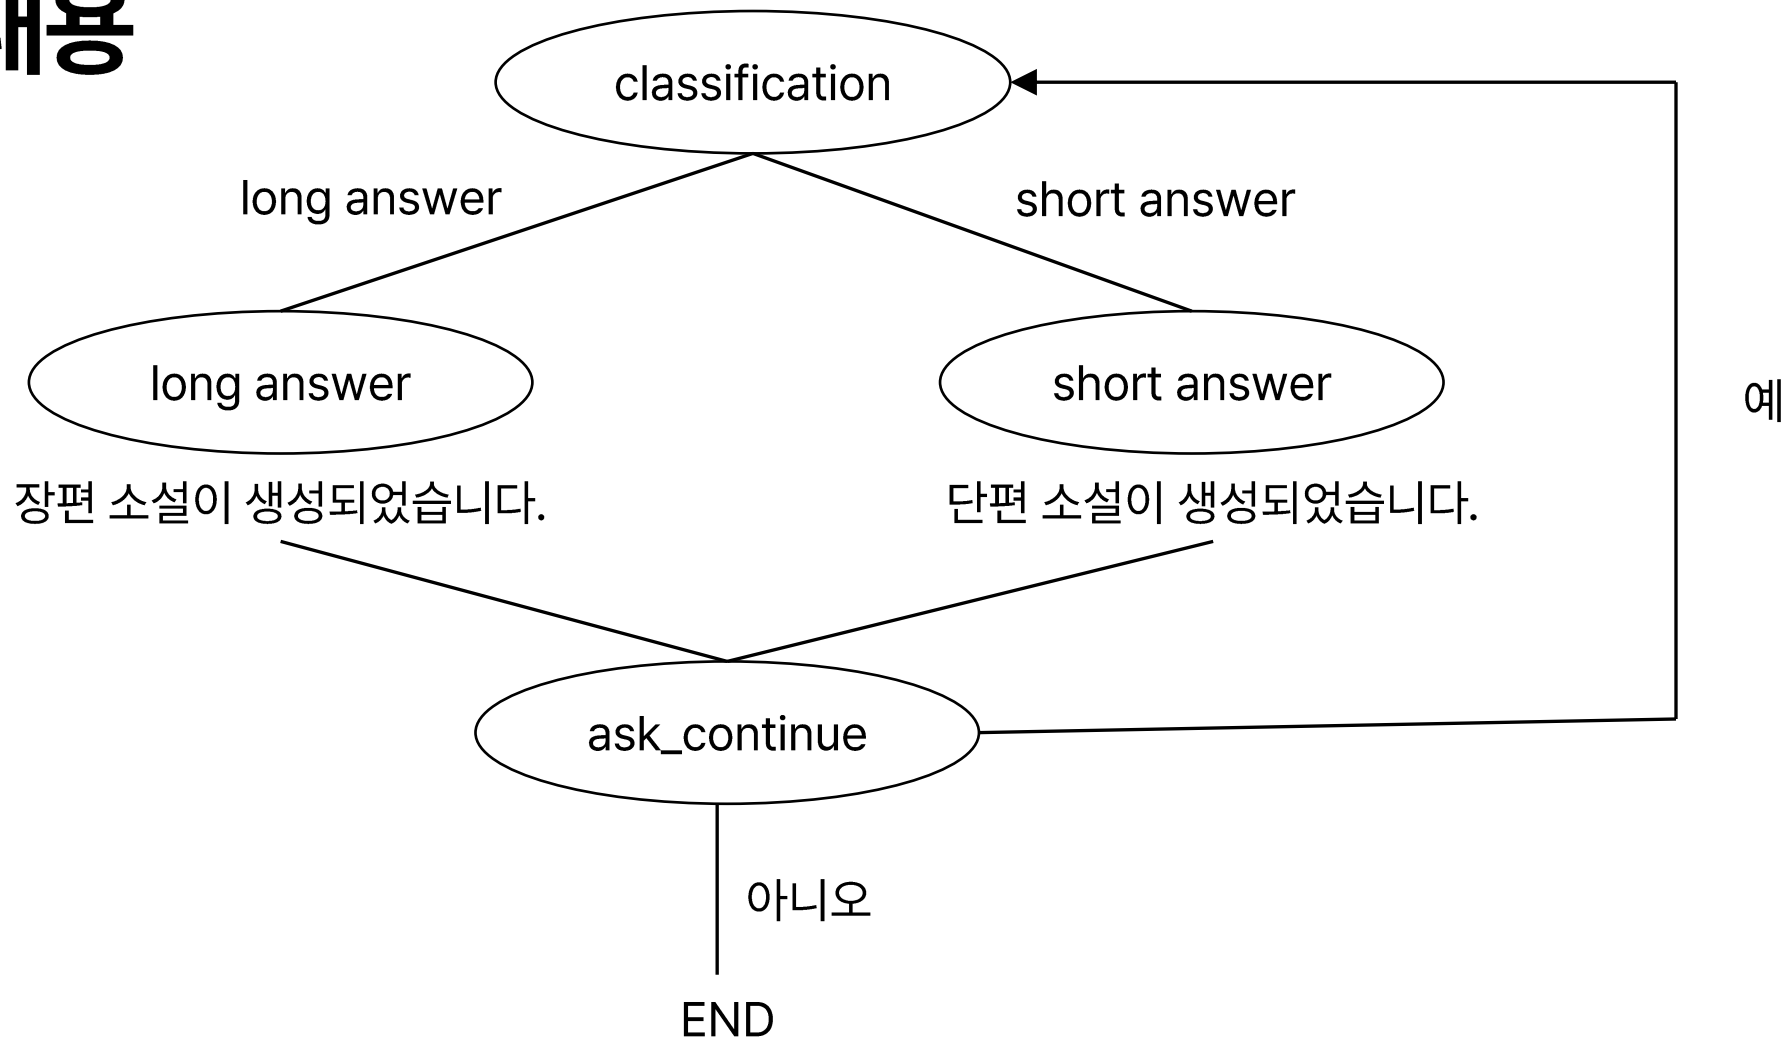
classification
long answer
short answer
long answer
short answer
장편 소설이 생성되었습니다.
단편 소설이 생성되었습니다.
ask_continue
예
아니오
END

Section

LangGraph + LangChain + multi-turn

라이브러리 불러오기 & 모델 설정

```
from langgraph.graph import StateGraph, END
from langchain_huggingface import HuggingFacePipeline
from langchain_core.prompts import PromptTemplate
from transformers import AutoTokenizer, AutoModelForCausalLM, pipeline
```

```
# 1. 모델 설정
model_id = "skt/kogpt2-base-v2"
tokenizer = AutoTokenizer.from_pretrained(model_id)
model = AutoModelForCausalLM.from_pretrained(model_id)
```

Section

LangGraph + LangChain + multi-turn

파이프라인 & 프롬프트 & 체인 생성

```
# 2. 파이프라인 생성
text_gen = pipeline(
    "text-generation",
    model=model,
    tokenizer=tokenizer,
    truncation=False,
    max_new_tokens=100,
    do_sample=True,
    return_full_text=True,
    temperature=0.7
)

llm = HuggingFacePipeline(pipeline=text_gen)
```

```
# 3. 프롬프트 및 체인
prompt = PromptTemplate.from_template("아주 먼 옛날 {user_input}이 살고 있었습니다. 그러던 어느날 ")
story_chain = prompt | llm
```

Section

LangGraph + LangChain + multi-turn

이야기 생성 및 분류 노드 생성

```python
# 이야기 생성 및 분류
def classification(state):
    user_input = state.get("user_input", "")
    story = story_chain.invoke({"user_input": user_input}).strip()
    label = "long_answer" if len(story) > 250 else "short_answer"
    return {**state, "label": label, "story": story}

# 4. 응답 노드
def long_answer(state):
    res = "장편 소설이 생성되었습니다."
    print(res)
    return {**state, "response": res}

def short_answer(state):
    res = "단편 소설이 생성되었습니다."
    print(res)
    return {**state, "response": res}
```

Section

LangGraph + LangChain + multi-turn

추가 질문 노드

```python
# 5. 사용자 질문 여부
def ask_continue(state):
    reply = input("\n추가 질문하시겠습니까? (예/아니오)\n> ").strip()
    if reply in ["예", "네", "yes", "Yes"]:
        state["continue"] = True
        question = input("추가 질문을 입력하세요:\n> ").strip()
        state["user_input"] = question
    else:
        state["continue"] = False
    return state

# 6. 분기: 계속할지 판단
def should_continue(state):
    if state.get("continue"):
        answer = "replay"
    else:
        answer = "__end__"
    return answer

# 7. 이전 스토리 기반 응답
def replay_story(state):
    question = state.get("user_input", "")
    if "보여줘" in question:
        print("\n이전에 생성된 이야기:\n", state.get("story", "[이야기가 없습니다]"))
        return {**state, "response": "이전 이야기 다시 보여줌"}
    else:
        # 새로운 동물 입력일 경우 새로운 이야기 생성
        return classification(state)
```

Section

LangGraph + LangChain + multi-turn

그래프 생성

```python
def get_label(state):
    return state.get("label", "")
```

```python
# 9. LangGraph 구성
graph = StateGraph(dict)
graph.add_node("classification", classification)
graph.add_node("long_answer", long_answer)
graph.add_node("short_answer", short_answer)
graph.add_node("ask_continue", ask_continue)
graph.add_node("replay", replay_story)

graph.set_entry_point("classification")

graph.add_conditional_edges("classification", get_label, {
    "long_answer": "long_answer",
    "short_answer": "short_answer"
})

graph.add_edge("long_answer", "ask_continue")
graph.add_edge("short_answer", "ask_continue")

graph.add_conditional_edges("ask_continue", should_continue, {
    "replay": "replay",
    "__end__": END
})

graph.add_edge("replay", "ask_continue")
```

Section

LangGraph + LangChain + multi-turn

실행

```python
# 10. 실행
app = graph.compile()

print("동물 이름을 입력해 이야기를 시작해보세요!")
user_input = input("동물 이름 입력: ")
final_state = app.invoke({"user_input": user_input})
print("\n대화 종료")
```

```
동물 이름을 입력해 이야기를 시작해보세요!
동물 이름 입력: 고양이
```

첫 번째 입력

```
장편 소설이 생성되었습니다.

추가 질문하시겠습니까? (예/아니오)
> 예
추가 질문을 입력하세요:
> 이전 이야기 보여줘
```

두 번째 입력

세 번째 입력

```
이전에 생성된 이야기:
 아주 먼 옛날 고양이이 살고 있었습니다. 그러던 어느날 뭔가 생각났습니다. 고양이를 데리고 집으로 들어갔더니 고양이를 데리고 산책을 하고 있었습니다. 저는 고양이를 주울 수 있는 방법을 찾아냈습니다. 고양이가 집을 떠나기 전에 이미 고양이를 데리고 간 뒤였습니다. 주인이 고양이를 데리고 집으로 돌아와 보니 주인은 고양이를 데리고 집에 들어갔습니다. 주인도 고양이를 안고 집으로 들어가 보았습니다. 주인도 고양이를 데리고 집으로 가 보았습니다. 고양이를 데리고 집에 들어온 고양이는 주인이 고양이를 안아 주려고 안간힘을 썼지만 아무도 오지 않았

추가 질문하시겠습니까? (예/아니오)
> 아니오
```

네 번째 입력

```
대화 종료
```

GEN AI 인텐시브 과정

Section 1. LangGraph

Section 1-4. LangGraph + LangChain + multi-turn + Memory + RAG(1)

실습 내용 RetrievalQA 사용

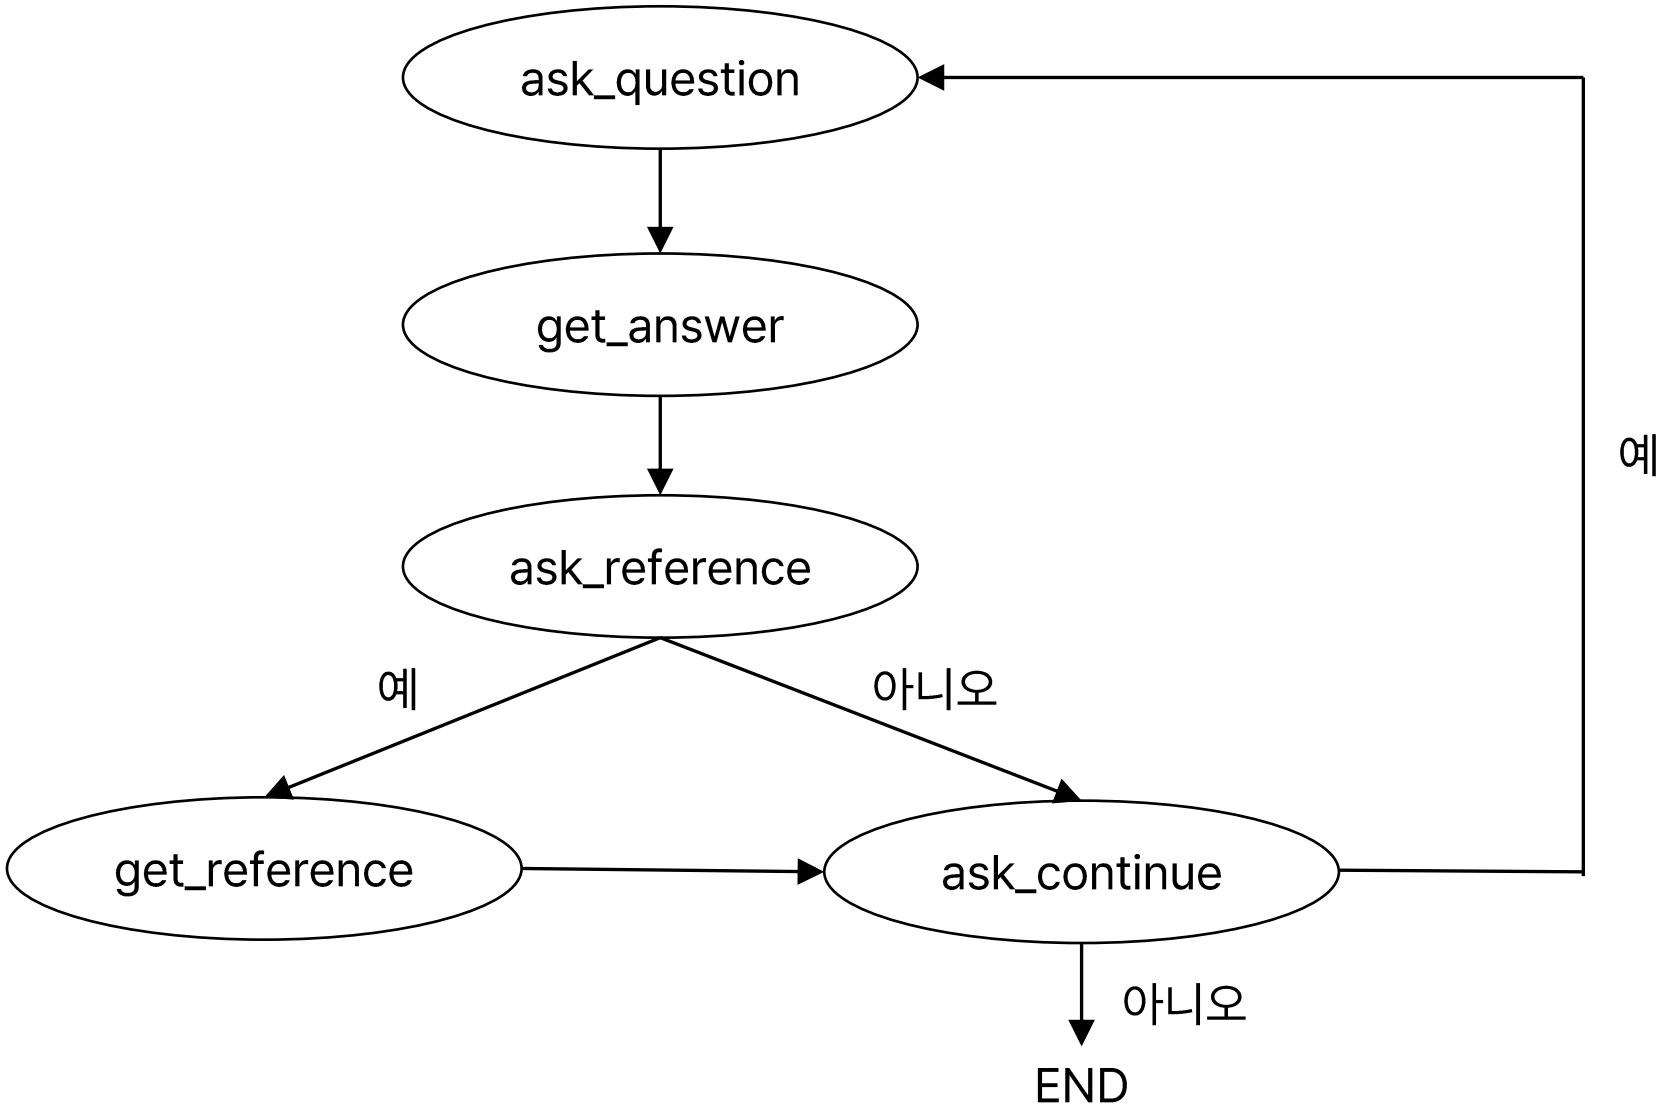

Section

LangGraph + LangChain + multi-turn + Memory + RAG(1)

라이브러리 & 데이터 불러오기

```
import pandas as pd
from langchain_chroma import Chroma
from langchain.schema import Document
from langgraph.graph import StateGraph, END
from langchain.chains import RetrievalQA
from langchain_huggingface import HuggingFaceEmbeddings
from langchain_huggingface import HuggingFacePipeline
from transformers import AutoTokenizer, AutoModelForCausalLM, pipeline
```

```
# 1. 문서 불러오기
df = pd.read_csv('./data/data.csv', encoding='utf-8')
df.head(10)
```

	text
0	Etching 공정 전에는 반드시 세정 공정이 완료되어야 합니다.
1	PM 장비의 필터는 주 1회 정기적으로 교체해야 합니다.

pandas -> chromaDB

```
# 2. 문서 리스트로 변환
texts = df["text"].tolist()
docs = [Document(page_content=text) for text in texts]
```

```
# 3. 임베딩 모델
embedding_model = HuggingFaceEmbeddings(model_name="sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2")
```

```
# 4. Chroma에 저장
vectorstore = Chroma.from_documents(
    documents=docs,
    embedding=embedding_model,
    persist_directory="./chromaDB"
)
```

모델 & 체인 생성

RetrievalQA 체인을 사용하기 위해서는
"text-generation 모델을 사용해야함."

```python
# 5. LLM 준비
model_id = "skt/kogpt2-base-v2"
tokenizer = AutoTokenizer.from_pretrained(model_id)
model = AutoModelForCausalLM.from_pretrained(model_id)

text_gen = pipeline(
    "text-generation",
    model=model,
    tokenizer=tokenizer,
    truncation=False,
    max_new_tokens=100,
    do_sample=True,
    return_full_text=True,
    temperature=0.7
)
```

RetrievalQA 체인 생성
- RAG 기반 질문 응답 시스템 구축시 사용
- 검색 -> 생성 과정을 합친 체인

1. 사용자 질문을 받는다(query)
2. retrieve를 통해 관련 문서 찾기
3. 찾은 문서 + 질문을 LLM에 넘김
4. LLM이 답변 생성

```python
llm = HuggingFacePipeline(pipeline=text_gen)

# 6. RAG QA 체인
qa_chain = RetrievalQA.from_chain_type(
    llm=llm,
    retriever=vectorstore.as_retriever(),
    return_source_documents=True
)
```

노드 설정

```python
# 7. 노드 설정
def ask_question(state):
    question = input("질문을 입력해주세요: ")
    result = qa_chain.invoke({"query": question})
    res = {
        "question": question,
        "answer": result["result"],
        "source_docs": result["source_documents"]
    }
    return res

def get_answer(state):
    print("\n답변:", state["answer"])
    return state

def ask_reference(state):
    reply = input("\n참고문서를 보시겠습니까? (예/아니오): ").strip()
    return {**state, "see_reference": reply}
```

RetrievalQA 체인의 입력키 이름이 “query”

RetrievalQA의 출력값은 딕셔너리이며, “result”에 정답이 포함되어 있음

RetrievalQA의 “source_documents”에 참고문서 포함

노드 설정

```python
def get_reference(state):
    print("\n[참고 문서]")
    for i, doc in enumerate(state["source_docs"], 1):
        print(f"{i}. {doc.page_content[:200]}...")
    return state

def ask_continue(state):
    reply = input("\n계속하시겠습니까? (예/아니오): ").strip()
    return {**state, "continue": reply}

def reference_or_not(state):
    return "get_reference" if state.get("see_reference") == "예" else "ask_continue"

def continue_or_not(state):
    return "ask_question" if state.get("continue") == "예" else END
```

Section

LangGraph + LangChain + multi-turn + Memory + RAG(1)

그래프 설계

```python
# 8. 그래프 구성
graph = StateGraph(dict)

# 노드 추가
graph.add_node("ask_question", ask_question)
graph.add_node("get_answer", get_answer)
graph.add_node("ask_reference", ask_reference)
graph.add_node("get_reference", get_reference)
graph.add_node("ask_continue", ask_continue)

# 시작점 설정
graph.set_entry_point("ask_question")

# 엣지 설정
graph.add_edge("ask_question", "get_answer")
graph.add_edge("get_answer", "ask_reference")
graph.add_conditional_edges("ask_reference", reference_or_not, {
    "get_reference": "get_reference",
    "ask_continue": "ask_continue"
})
graph.add_edge("get_reference", "ask_continue")
graph.add_conditional_edges("ask_continue", continue_or_not, {
    "ask_question": "ask_question",
    END: END
})
```

```
<langgraph.graph.state.StateGraph at 0x21fd303f650>
```

실행

```
# 9. 실행
app = graph.compile()
app.invoke({})
```

```
질문을 입력해주세요: MES 공정 로그 보관 기간은?
```

첫 번째 입력

```
답변: Use the following pieces of context to answer the question at the end. If you don't know the answer, just say th
e up an answer.

MES 시스템에 기록된 공정 로그는 6개월간 보관됩니다.

공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다.

소자 특성 분석 결과는 전자문서 시스템에 등록합니다.

이온 주입 공정 후 열처리 시간은 최소 30분 이상 확보합니다.

Question: MES 공정 로그 보관 기간은?
Helpful Answer: Hellpful Answer: Hellpful Answer: Hellpful Answer: Hellpful Answer: Hellpful Answer: Hellpful Answer:
ellpful Answer: Hellpful Answer:
```

실행

참고문서를 보시겠습니까? (예/아니오): 예

두 번째 입력

[참고 문서]
1. MES 시스템에 기록된 공정 로그는 6개월간 보관됩니다....
2. 공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다....
3. 소자 특성 분석 결과는 전자문서 시스템에 등록합니다....
4. 이온 주입 공정 후 열처리 시간은 최소 30분 이상 확보합니다....

실행

계속하시겠습니까? (예/아니오): 예 세 번째 입력
질문을 입력해주세요: 클린룸 입장시 주의 사항 알려줘 네 번째 입력

```
답변: Use the following pieces of context to answer the question at the end. If you don't know the
e up an answer.

공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다.

장비 재가동 시 Warm-up 절차를 반드시 이행합니다.

Etching 공정 전에는 반드시 세정 공정이 완료되어야 합니다.

클린룸 입장 전에는 반드시 정전기 방지복을 착용해야 합니다.

Question: 클린룸 입장시 주의 사항 알려줘
Helpful Answer: 클린룸 입장시 주의 사항
Attitude: 클린룸 입장시 주의 사항
Schedule: 클린룸 입장시 주의 사항
Salvation: 클린룸 입장시 주의 사항
Attitude: 클린룸 입장시 주의 사항
There's prepared by the corporate of the question at the end of the question from the end of the
```

실행

참고문서를 보시겠습니까? (예/아니오): 예 다섯 번째 입력

```
[참고 문서]
1. 공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다....
2. 장비 재가동 시 Warm-up 절차를 반드시 이행합니다....
3. Etching 공정 전에는 반드시 세정 공정이 완료되어야 합니다....
4. 클린룸 입장 전에는 반드시 정전기 방지복을 착용해야 합니다....
```

계속하시겠습니까? (예/아니오): 아니오 여섯 번째 입력

```
{'question': '클린룸 입장시 주의 사항 알려줘',
 'answer': "Use the following pieces of context to answer the question at the end. If you don't know th
to make up an answer.\n\n공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다.\n\n장비 재가동 시 Warm-up 절차를
공정이 완료되어야 합니다.\n\n클린룸 입장 전에는 반드시 정전기 방지복을 착용해야 합니다.\n\nQuestion: 클린룸 입
주의 사항\nAttitude: 클린룸 입장시 주의 사항\nSchedule: 클린룸 입장시 주의 사항\nSalvation: 클린룸 입장시 주
repared by the corporate of the question at the end of the question from the end of the ",
 'source_docs': [Document(metadata={}, page_content='공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다.'),
  Document(metadata={}, page_content='장비 재가동 시 Warm-up 절차를 반드시 이행합니다.'),
  Document(metadata={}, page_content='Etching 공정 전에는 반드시 세정 공정이 완료되어야 합니다.'),
  Document(metadata={}, page_content='클린룸 입장 전에는 반드시 정전기 방지복을 착용해야 합니다.')],
 'see_reference': '예',
 'continue': '아니오'}
```

GEN AI 인텐시브 과정

Section 1. LangGraph

Section 1-4. LangGraph + LangChain + multi-turn + Memory + RAG(2)

실습 내용 RetrievalQA 미사용

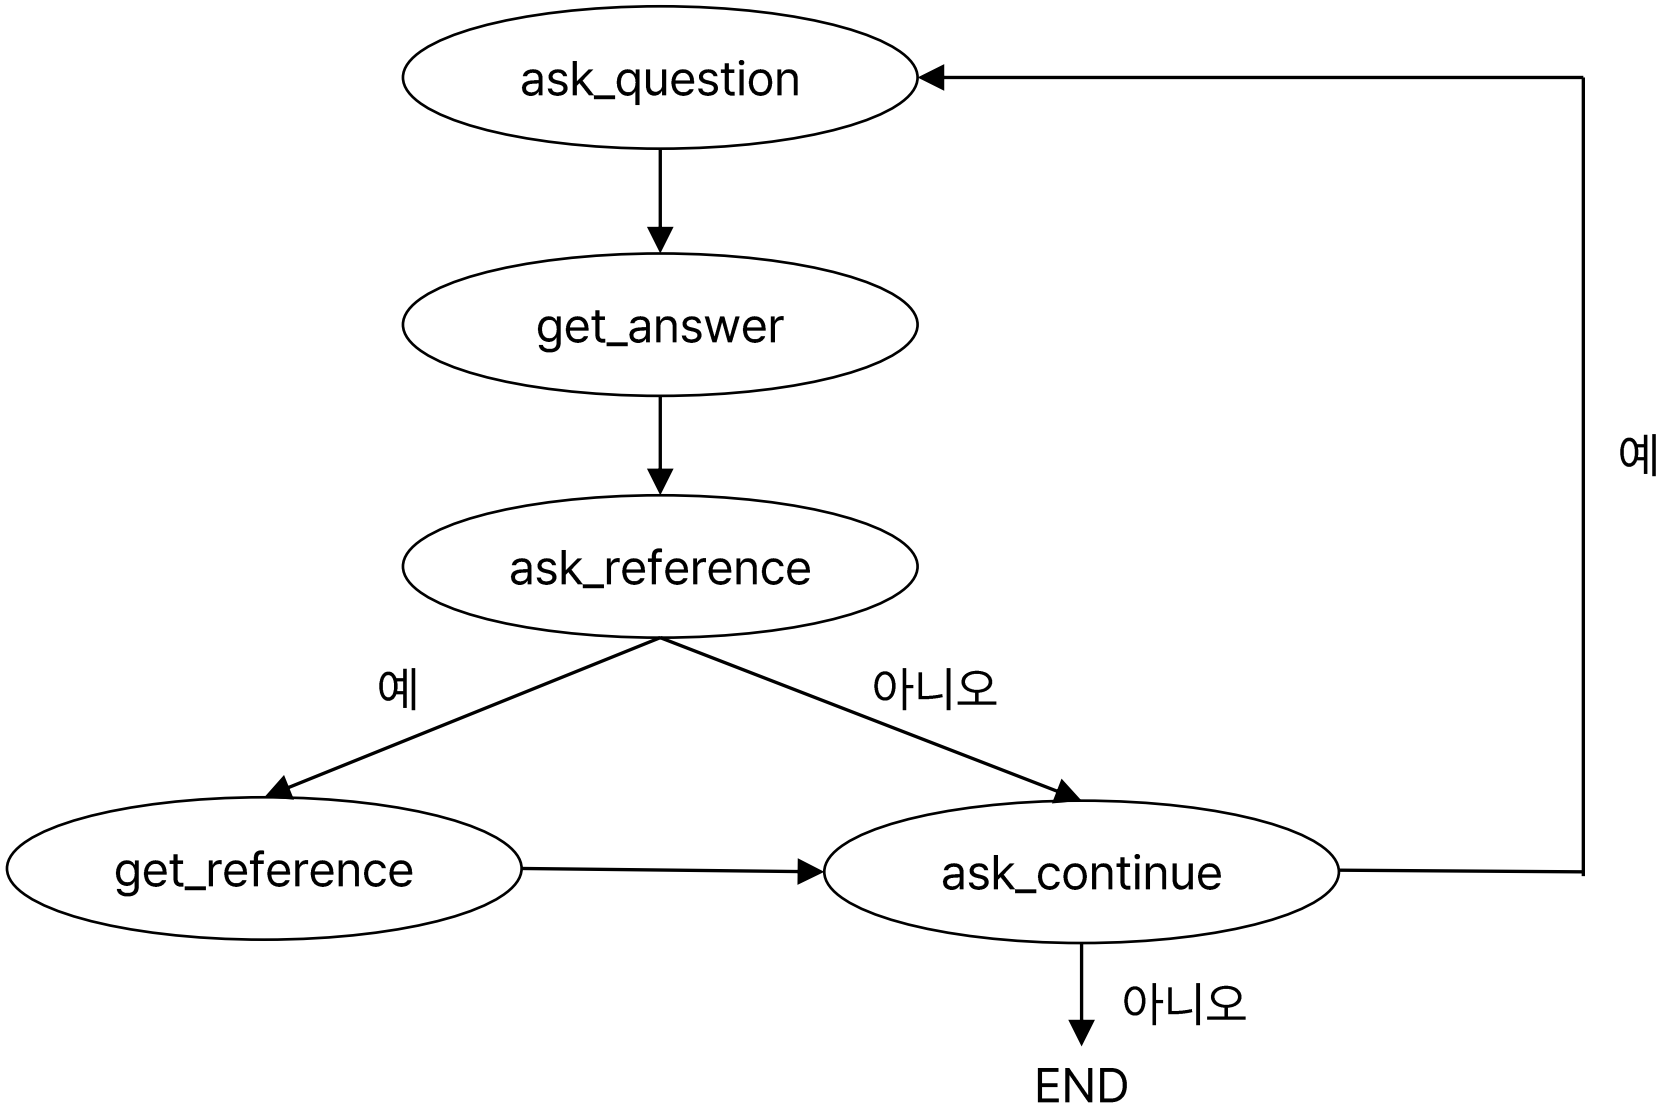

Section

LangGraph + LangChain + multi-turn + Memory + RAG(2)

라이브러리 & 데이터 불러오기

```
from langchain_chroma import Chroma
from langgraph.graph import StateGraph, END
from langchain_huggingface import HuggingFaceEmbeddings
from langchain_huggingface import HuggingFacePipeline
from transformers import AutoTokenizer, AutoModelForQuestionAnswering, pipeline
```

```
# 1. 임베딩 모델
embedding_model = HuggingFaceEmbeddings(model_name="sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2")
```

```
# 2. 저장된 ChromaDB 불러오기
retriever = Chroma(
    persist_directory="./chromaDB",
    embedding_function=embedding_model
).as_retriever(search_kwargs={"k": 3})
```

Section

LangGraph + LangChain + multi-turn + Memory + RAG(2)

모델 & 파이프라인 설정

```
# 3. KoELECTRA QA 모델 로딩
model_id = "monologg/koelectra-base-v3-finetuned-korquad"
qa_tokenizer = AutoTokenizer.from_pretrained(model_id)
qa_model = AutoModelForQuestionAnswering.from_pretrained(model_id)
```

```
# 4. 파이프라인 & LangChain 래핑
text_gen = pipeline(
    "question-answering",
    model=qa_model,
    tokenizer=qa_tokenizer,
    device=-1,
    max_length=512,
    do_sample=False,
    temperature=0.1,
    truncation=True
)
```

노드 설정

```python
# 5. 노드 설정
def ask_question(state):
    question = input("질문을 입력해주세요: ").strip()
    docs = retriever.invoke(question)
    top_docs = docs[:3]
    best_contexts = [doc.page_content for doc in top_docs]
    combined_context = "\n".join(best_contexts)
    result = text_gen(question=question, context=combined_context)
    res = {
        "question": question,
        "answer": result["answer"],
        "context": best_contexts
    }
    return res

def get_answer(state):
    print(f"\n질문: {state['question']}")
    print(f"답변: {state['answer']}")
    return state
```

노드 설정

```python
def ask_reference(state):
    user_input = input("\n 참고 문서를 보시겠습니까? (예/아니오): ").strip()
    state["show_reference"] = user_input.startswith("예")
    return state

def get_reference(state):
    if state.get("show_reference"):
        print("\n 참고 문서:\n", state["context"])
    return state

def ask_continue(state):
    user_input = input("\n 계속하시겠습니까? (예/아니오): ").strip()
    state["continue"] = user_input.startswith("예")
    return state

# 분기 함수
def should_show_reference(state):
    return "get_reference" if state.get("show_reference") else "ask_continue"

def should_continue(state):
    return "ask_question" if state.get("continue") else END
```

Section

LangGraph + LangChain + multi-turn + Memory + RA

그래프 구성

```python
# 6. 그래프 구성
graph = StateGraph(dict)

# 노드 추가
graph.add_node("ask_question", ask_question)
graph.add_node("get_answer", get_answer)
graph.add_node("ask_reference", ask_reference)
graph.add_node("get_reference", get_reference)
graph.add_node("ask_continue", ask_continue)

# 시작점 설정
graph.set_entry_point("ask_question")

# 엣지 설정
graph.add_edge("ask_question", "get_answer")
graph.add_edge("get_answer", "ask_reference")
graph.add_conditional_edges("ask_reference", should_show_reference, {
    "get_reference": "get_reference",
    "ask_continue": "ask_continue"
})
graph.add_edge("get_reference", "ask_continue")
graph.add_conditional_edges("ask_continue", should_continue, {
    "ask_question": "ask_question",
    END: END
})
```

Section

LangGraph + LangChain + multi-turn + Memory + RAG(2)

```
# 7. 실행
app = graph.compile()
app.invoke({})
```

```
질문을 입력해주세요: MES 공정 로그 보관 기간은?
```
첫 번째 입력

```
질문: MES 공정 로그 보관 기간은?
답변: 6개월간

참고 문서를 보시겠습니까? (예/아니오): 예
```
두 번째 입력

```
 참고 문서:
 ['MES 시스템에 기록된 공정 로그는 6개월간 보관됩니다.', '공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다.', '소자 특성 분석 결과는 전자문서 시스템에 등록합니다.']

계속하시겠습니까? (예/아니오): 예
```
세 번째 입력

```
질문을 입력해주세요: 클린룸 입장 시 주의사항 알려줘
```
네 번째 입력

```
질문: 클린룸 입장 시 주의사항 알려줘
답변: 반드시

참고 문서를 보시겠습니까? (예/아니오): 예
```
다섯 번째 입력

```
 참고 문서:
 ['공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다.', '장비 재가동 시 Warm-up 절차를 반드시 이행합니다.', 'Etching 공정 전에는 반드시 세정 공정이 완료되어야 합니다.']

계속하시겠습니까? (예/아니오): 아니오
```
여섯 번째 입력

```
{'question': '클린룸 입장 시 주의사항 알려줘',
 'answer': '반드시',
 'context': ['공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다.',
  '장비 재가동 시 Warm-up 절차를 반드시 이행합니다.',
  'Etching 공정 전에는 반드시 세정 공정이 완료되어야 합니다.'],
 'show_reference': True,
 'continue': False}
```

LangGraph

Section 1. LangGraph

Section 1-5. LangGraph + LangChain + multi-turn + Memory + RAG(3)

Section

LangGraph + LangChain + multi-turn + Memory + RAG(3)

실습 내용 RetrievalQA 미사용

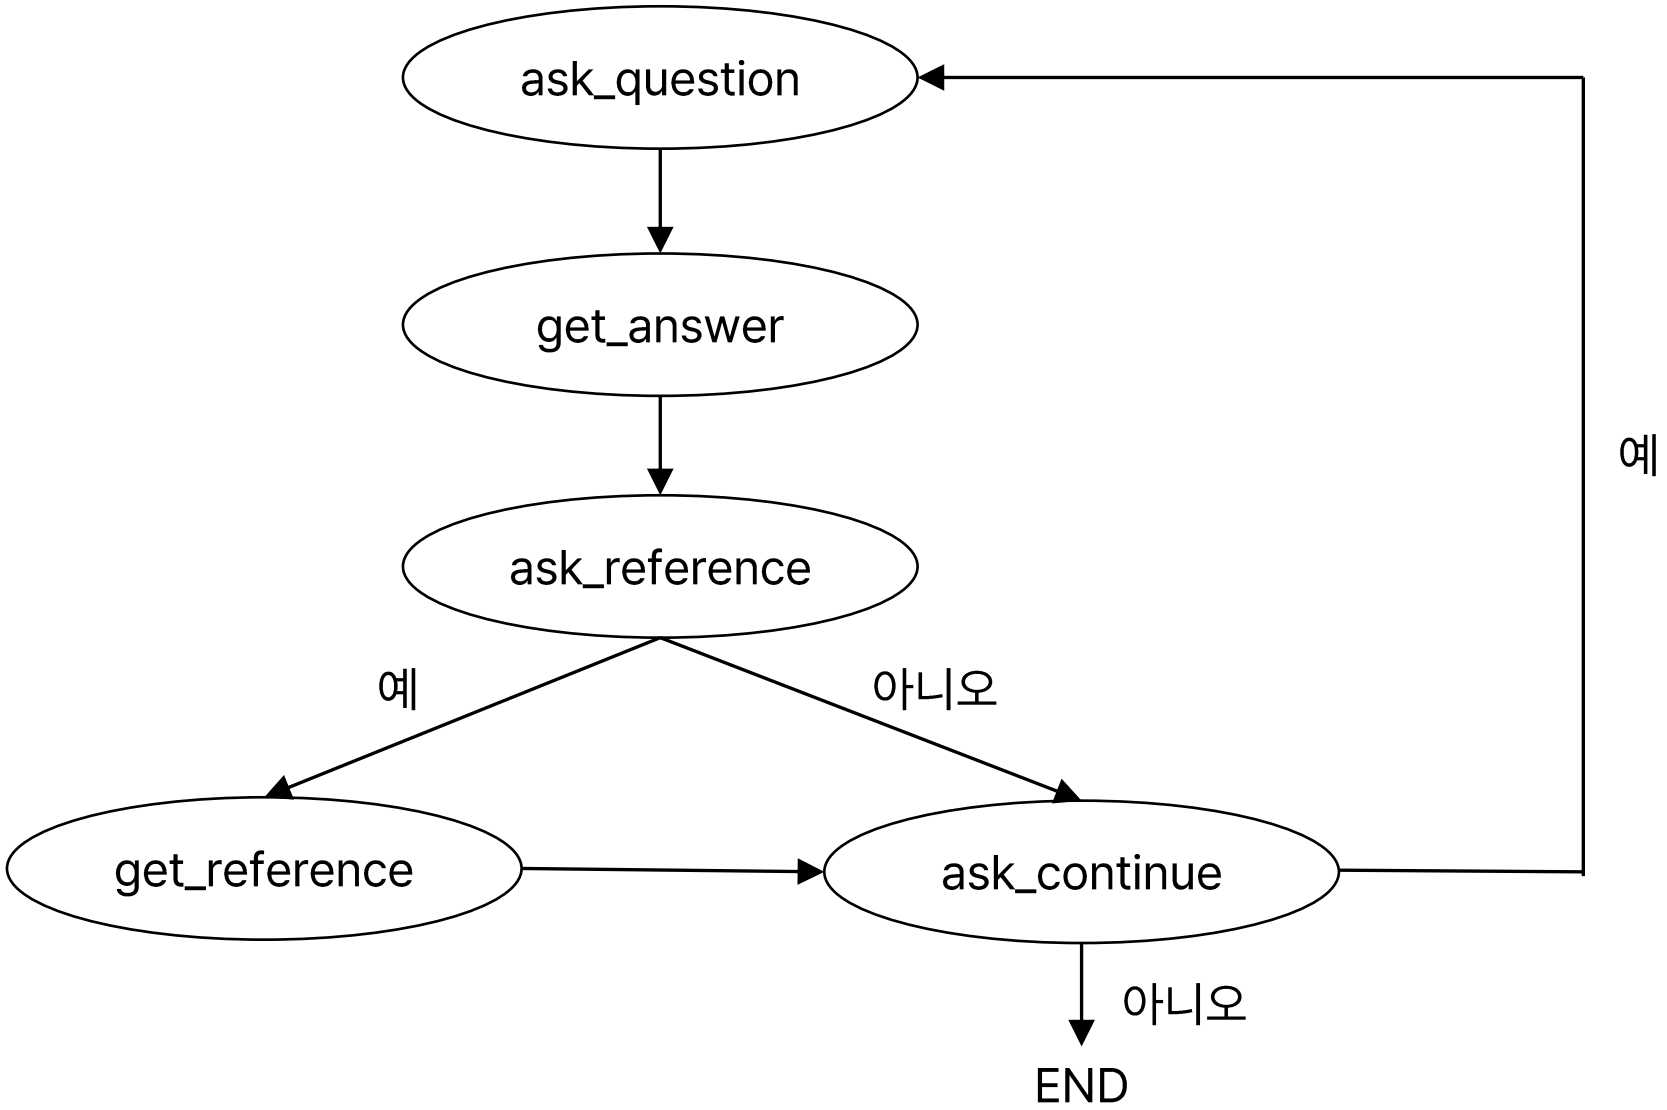

Section

LangGraph + LangChain + multi-turn + Memory + RAG(3)

라이브러리 & 데이터 불러오기

```
import uuid
from langchain_chroma import Chroma
from langgraph.graph import StateGraph, END
from langchain_huggingface import HuggingFaceEmbeddings, HuggingFacePipeline
from transformers import AutoTokenizer, AutoModelForQuestionAnswering, pipeline
from langchain_core.chat_history import InMemoryChatMessageHistory
from langchain_core.messages import get_buffer_string
from langchain_core.runnables import RunnableConfig
from langchain_core.chat_history import BaseChatMessageHistory
```

```
# 1. 임베딩 모델
embedding_model = HuggingFaceEmbeddings(model_name="sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2")

# 2. 저장된 ChromaDB 불러오기
retriever = Chroma(
    persist_directory="./chromaDB",
    embedding_function=embedding_model
).as_retriever(search_kwargs={"k": 3})
```

Section

LangGraph + LangChain + multi-turn + Memory + RAG(3)

모델 로딩 & 파이프라인

```
# 3. KoELECTRA QA 모델 로딩
model_id = "monologg/koelectra-base-v3-finetuned-korquad"
qa_tokenizer = AutoTokenizer.from_pretrained(model_id)
qa_model = AutoModelForQuestionAnswering.from_pretrained(model_id)
```

```
# 4. 파이프라인 & LangChain 래핑
text_gen = pipeline(
    "question-answering",
    model=qa_model,
    tokenizer=qa_tokenizer,
    device=-1,
    max_length=512,
    do_sample=False,
    temperature=0.1,
    truncation=True
)
llm = HuggingFacePipeline(pipeline=text_gen)
```

```
Device set to use cpu
```

히스토리 관리

```python
# 5. 히스토리 관리
chats_by_session_id = {}

def get_chat_history(session_id: str) -> BaseChatMessageHistory:
    if session_id not in chats_by_session_id:
        chats_by_session_id[session_id] = InMemoryChatMessageHistory()
    return chats_by_session_id[session_id]
```

노드 생성

```python
# 6. 노드 정의
def ask_question(state, config: RunnableConfig):
    session_id = config["configurable"]["session_id"]
    chat_history = get_chat_history(session_id)

    question = input("질문을 입력해주세요: ").strip()
    docs = retriever.invoke(question)
    top_docs = docs[:3]
    best_contexts = [doc.page_content for doc in top_docs]
    combined_context = "\n".join(best_contexts)

    history_text = get_buffer_string(chat_history.messages)
    full_context = f"{history_text}\n\n{combined_context}" if history_text else combined_context

    result = text_gen(question=question, context=full_context)

    chat_history.add_user_message(question)
    chat_history.add_ai_message(result["answer"])

    return {
        "question": question,
        "answer": result["answer"],
        "context": best_contexts
    }
```

노드 생성

```python
def get_answer(state):
    print(f"\n질문: {state['question']}")
    print(f"답변: {state['answer']}")
    return state

def ask_reference(state):
    user_input = input("\n참고 문서를 보시겠습니까? (예/아니오): ").strip()
    state["show_reference"] = user_input.startswith("예")
    return state

def get_reference(state):
    if state.get("show_reference"):
        print("\n참고 문서:\n")
        for i, ctx in enumerate(state["context"], 1):
            print(f"[{i}] {ctx}\n")
    return state

def ask_continue(state):
    user_input = input("\n계속하시겠습니까? (예/아니오): ").strip()
    state["continue"] = user_input.startswith("예")
    return state

def should_show_reference(state):
    return "get_reference" if state.get("show_reference") else "ask_continue"

def should_continue(state):
    return "ask_question" if state.get("continue") else END
```

그래프 생성

```python
# 7. LangGraph 구성
graph = StateGraph(dict)
graph.add_node("ask_question", ask_question)
graph.add_node("get_answer", get_answer)
graph.add_node("ask_reference", ask_reference)
graph.add_node("get_reference", get_reference)
graph.add_node("ask_continue", ask_continue)

graph.set_entry_point("ask_question")
graph.add_edge("ask_question", "get_answer")
graph.add_edge("get_answer", "ask_reference")
graph.add_conditional_edges("ask_reference", should_show_reference, {
    "get_reference": "get_reference",
    "ask_continue": "ask_continue"
})
graph.add_edge("get_reference", "ask_continue")
graph.add_conditional_edges("ask_continue", should_continue, {
    "ask_question": "ask_question",
    END: END
})
```

```
<langgraph.graph.state.StateGraph at 0x792e5334fd10>
```

실행

```python
# 8. 실행
session_id = str(uuid.uuid4())  # 고유 세션 ID
config = {"configurable": {"session_id": session_id}}

app = graph.compile()
app.invoke({}, config=config)
```

```
질문을 입력해주세요: MES 공정 로그 보관 기간은?
```

첫 번째 입력

```
질문: MES 공정 로그 보관 기간은?
답변: 6개월간

참고 문서를 보시겠습니까? (예/아니오): 예
```

두 번째 입력

```
참고 문서:

[1] MES 시스템에 기록된 공정 로그는 6개월간 보관됩니다.

[2] 공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다.

[3] 소자 특성 분석 결과는 전자문서 시스템에 등록합니다.
```

실행

```
계속하시겠습니까? (예/아니오): 예
```
세 번째 입력

```
질문을 입력해주세요: 그럼 MES 공정 보관 기간이 지나면 사용할 수 없니?
```
네 번째 입력

```
질문: 그럼 MES 공정 보관 기간이 지나면 사용할 수 없니?
답변: 6개월간

참고 문서를 보시겠습니까? (예/아니오): 예
```
다섯 번째 입력

```
참고 문서:

[1] 공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다.

[2] MES 시스템에 기록된 공정 로그는 6개월간 보관됩니다.

[3] Etching 공정 전에는 반드시 세정 공정이 완료되어야 합니다.


계속하시겠습니까? (예/아니오): 아니오
```
여섯 번째 입력

[12]:
```
{'question': '그럼 MES 공정 보관 기간이 지나면 사용할 수 없니?',
 'answer': '6개월간',
 'context': ['공정 이탈 발생 시 Shift 리더에게 즉시 보고합니다.',
  'MES 시스템에 기록된 공정 로그는 6개월간 보관됩니다.',
  'Etching 공정 전에는 반드시 세정 공정이 완료되어야 합니다.'],
 'show_reference': True,
 'continue': False}
```

감사합니다.

Q & A